

二、流式处理与实时通信（25题）

1. 请设计一个支持"断线重连+消息去重"的SSE客户端，并处理AI长文本生成中的网络抖动问题

场景：在"印客学院"的AI答疑系统中，学生提问后AI需要长时间生成答案，期间网络可能不稳定，需要确保连接中断后能自动重连，并且不丢失、不重复已接收数据。

核心答案：

设计一个SSE客户端，封装原生 `EventSource`，添加以下功能：

1. **断线重连：**监听 `onerror` 事件，连接断开后按指数退避策略重连
2. **消息去重：**服务器为每个消息分配唯一ID，客户端记录已接收的最后一个ID，重连时通过 `Last-Event-ID` 头告知服务器
3. **网络抖动处理：**设置合理 `retry` 时间，客户端检测长时间无消息时发送心跳包

实现要点：

- 使用 `EventSource` 的 `retry` 字段和 `lastEventId` 机制
- 客户端记录最后接收的消息ID，重连时传入
- 设置心跳检测，长时间无数据主动重连
- 使用指数退避算法控制重连间隔

代码示例：

代码块

```
1 class InkeSSEClient {
2     private eventSource: EventSource | null = null;
3     private lastEventId: string = '';
4     private retryCount = 0;
5     private maxRetries = 5;
6     private retryDelay = 1000;
7
8     connect(url: string) {
9         const eventSourceInitDict: EventSourceInit = {};
10        if (this.lastEventId) {
11            eventSourceInitDict.lastEventId = this.lastEventId;
12        }
13
14        this.eventSource = new EventSource(url, eventSourceInitDict);
15    }
```

```
16     this.eventSource.onmessage = (event) => {
17         this.retryCount = 0;
18         this.retryDelay = 1000;
19
20         if (event.lastEventId) {
21             this.lastEventId = event.lastEventId;
22         }
23         // 处理消息
24     };
25
26     this.eventSource.onerror = () => {
27         this.eventSource?.close();
28         if (this.retryCount < this.maxRetries) {
29             setTimeout(() => {
30                 this.retryCount++;
31                 this.retryDelay *= 2;
32                 this.connect(url);
33             }, this.retryDelay);
34         }
35     };
36 }
37 }
```

2. 如何在前端实现一个"流式Markdown解析器"，在AI逐字输出过程中实时渲染标题、列表、代码块，并避免标签截断？

场景："印客学院"的AI在回答技术问题时流式输出Markdown格式文本，需实时渲染并保证结构完整性。

核心答案：使用增量解析策略，维护解析状态，只解析新增部分。避免在标签中间截断导致HTML解析错误。

实现要点：

1. 使用 `marked` 库的 `lexer` 进行词法分析
2. 维护token队列，每次只对新内容进行词法分析
3. 检测未闭合结构（如代码块），暂不渲染
4. 使用 `requestAnimationFrame` 控制渲染频率

处理流程：

- 新文本到达 → 词法分析得到新tokens
- 合并到现有token队列

- 检查当前是否有未闭合结构
- 渲染所有完整tokens
- 未闭合结构用占位符显示

3. 当AI流式返回的数据包含多个独立片段时，如何设计Chunk合并算法以保证片段完整性？


场景："印客学院"的AI在回答复杂问题时，交替生成文本、代码、表格等多种内容，每个类型可能分多次返回。

核心答案：设计基于"边界检测"的合并算法。为每种内容类型定义开始和结束标记，使用状态机分析新Chunk，决定创建新片段、追加到现有片段还是结束片段。

算法步骤：

1. 定义片段类型和边界标记（代码块用``，表格用|）
2. 维护当前活跃片段
3. 对于每个新Chunk：
 - 检测是否包含开始标记 → 开始新片段
 - 检测是否包含结束标记 → 结束当前片段
 - 否则 → 追加到当前片段
4. 片段完成后加入已完成列表

状态转换：



4. 请实现一个支持"优先级调度"的流式请求队列，允许用户中断低优先级生成以优先处理高优先级任务

场景："印客学院"学习平台中，学生可能同时发起多个AI请求，如翻译句子（低优先级）和生成代码（高优先级）。

核心答案：设计请求队列，每个请求带有优先级属性。队列管理器根据优先级调度请求，同一时间只执行一个请求。高优先级请求可中断低优先级请求。

实现要点：

1. 请求封装为任务，包含优先级、可取消的异步函数
2. 队列按优先级排序，高优先级先执行
3. 当前执行任务可被中断（通过AbortController）
4. 中断后任务状态保存，可重新加入队列

队列管理逻辑：

- 添加任务 → 按优先级插入队列
- 执行任务 → 从队列取最高优先级任务
- 高优先级任务到达 → 中断当前低优先级任务
- 任务完成/中断 → 处理下一个任务

5. 在React 18+中，如何用useTransition与useDeferredValue优化AI流式输出的渲染性能，避免主线程阻塞？

场景："印客学院"的React前端中，AI流式输出导致组件频繁重渲染，可能阻塞主线程，影响用户交互。

核心答案： `useTransition` 标记状态更新为"非紧急"，React在空闲时处理；
`useDeferredValue` 延迟更新某个值，提供"滞后"版本，让界面先显示旧内容。

优化策略：

1. 将AI流式输出的状态更新包裹在 `startTransition` 中
2. 使用 `useDeferredValue` 延迟显示快速变化的流式文本
3. 利用 `isPending` 显示加载状态
4. 配合 `Suspense` 处理加载状态

代码结构：

代码块

```
1 function AIStreamComponent() {
2   const [text, setText] = useState('');
3   const [isPending, startTransition] = useTransition();
4   const deferredText = useDeferredValue(text);
```

```
5
6   const handleStream = (chunk) => {
7     startTransition(() => {
8       setText(prev => prev + chunk);
9     });
10  };
11
12  return (
13    <>
14      {isPending && <LoadingIndicator />}
15      <div>{deferredText}</div>
16    </>
17  );
18 }
```

6. 设计一个"流式数据缓存"策略，将AI已生成的内容分段存储于IndexedDB，支持离线续写与历史回放

场景："印客学院"的AI写作助手生成长篇文章时，用户可能中途离开，希望下次能继续之前内容。

核心答案：将AI生成的流式数据按时间或逻辑分段存储到IndexedDB，每个片段包含元数据。提供API支持离线续写和历史回放。

存储结构：

代码块

```
1  interface StreamChunk {
2    id?: number;
3    sessionId: string;    // 会话ID
4    chunkIndex: number;   // 片段序号
5    content: string;      // 内容
6    timestamp: number;    // 时间戳
7    isFinal: boolean;     // 是否结束
8  }
```

核心功能：

1. 保存片段：按顺序存储到IndexedDB
2. 获取会话片段：按sessionId查询，按chunkIndex排序
3. 获取最后片段：用于续写
4. 回放功能：按时间间隔"播放"历史片段

5. 清理策略：按时间或数量清理旧数据

7. 如何用Web Worker并行处理多个AI流式响应，并实现跨线程状态同步？

场景："印客学院"的智能批改系统需要同时处理多个学生作业，每个作业的AI评语都是流式生成。

核心答案：将每个AI流式请求分配给独立Web Worker处理，Worker负责接收流数据、解析、处理，通过postMessage将结果发送回主线程。

架构设计：

1. 创建Worker池管理多个Worker实例
2. 每个Worker处理一个独立AI流
3. 主线程通过MessageChannel与Worker通信
4. 使用Transferable Objects高效传输数据

主线程管理：

- Worker池：管理可用Worker
- 任务队列：待处理任务
- 任务分发：空闲Worker执行任务
- 状态同步：通过消息传递更新UI

Worker职责：

- 建立SSE连接
 - 解析流式数据
 - 处理数据（如格式化）
 - 发送结果回主线程
-

8. 当AI服务端返回的流式数据包含自定义事件时，前端如何解析并触发相应回调？

场景："印客学院"的AI服务除了返回文本内容，还会发送自定义事件，如生成开始/结束、工具调用请求、错误信息等。

核心答案：设计事件驱动的解析器，为每种事件类型注册处理器。解析SSE流时，提取 `event` 字段，根据事件类型分发到对应回调函数。

事件格式：

```
代码块
1 event: <事件类型>
2 data: <JSON数据>
3 id: <事件ID>
4 retry: <重试时间>
```

解析器设计：

1. 解析SSE格式，提取event、data、id、retry字段
2. 建立事件类型到处理函数的映射表
3. 根据event字段调用对应处理器
4. 提供默认处理器处理未知事件

处理器注册：

代码块

```
1 parser.on('message', (data) => { /* 处理消息 */ });
2 parser.on('tool_call', (data) => { /* 处理工具调用 */ });
3 parser.on('error', (data) => { /* 处理错误 */ });
```

9. 请设计一个"流式进度估算"组件，根据已接收的Token数与模型速率，动态预测AI生成剩余时间

场景："印客学院"的AI写作助手中，用户希望看到文章生成的预计剩余时间。

核心答案：基于已接收Token数量、接收时间间隔和模型理论生成速度，使用加权移动平均算法估算剩余时间。考虑网络波动、服务器负载等因素，提供置信区间。

估算算法：

1. 记录每个Token的到达时间戳
2. 计算最近N个Token的平均生成速度（加权平均，最近权重高）
3. 根据总Token数估算和已生成Token数计算剩余Token
4. 使用当前速度估算剩余时间
5. 计算速度方差，提供乐观/悲观估计范围

关键指标：

- 当前速度：最近N个Token的平均生成速度
- 剩余Token：总估计Token数 - 已生成Token数
- 剩余时间：剩余Token / 当前速度

- 置信区间：基于速度方差计算
-

10. 如何实现AI流式输出的"语音同步朗读"，确保语音与文字逐句对应，并支持暂停、跳过？

场景："印客学院"的听力练习中，AI生成的英文句子需要同步朗读，用户可能暂停、跳过某句，或调整朗读速度。

核心答案：使用Web Speech API的SpeechSynthesis实现TTS，结合句子边界检测算法将流式文本分割为句子，为每个句子创建独立语音任务队列。

实现步骤：

1. 句子边界检测：基于标点、换行分割文本
2. 语音队列管理：按句子顺序播放，支持控制操作
3. 文字高亮同步：朗读时高亮当前句子
4. 控制功能：播放、暂停、停止、跳过、语速调整

队列管理：

- 添加句子到队列
 - 按顺序播放队列中的句子
 - 当前句子播放完成后播放下一个
 - 支持中断当前句子，跳转到指定句子
-

11. 在微前端场景下，多个子应用同时订阅同一个AI流式连接，如何设计共享连接管理器以避免重复请求？

场景："印客学院"的微前端架构中，多个子应用（聊天、笔记、作业）都需要接收同一个AI助手的流式输出。

核心答案：设计共享的AI流式连接管理器作为单例运行在主应用或独立共享层中。子应用通过消息总线订阅流式数据，由管理器统一维护连接状态、重连逻辑，并将数据广播给所有订阅者。

管理器设计：

1. 单例模式：确保全局只有一个连接管理器
2. 订阅/发布模式：子应用订阅感兴趣的数据
3. 连接池管理：根据需要建立/关闭连接
4. 引用计数：当最后一个订阅者取消订阅时关闭连接
5. 数据广播：将接收到的数据发送给所有订阅者

订阅机制：

代码块

```
1  class SharedConnectionManager {
2      private subscribers = new Set<Subscriber>();
3
4      subscribe(callback) {
5          this.subscribers.add(callback);
6          if (this.subscribers.size === 1) {
7              this.connect(); // 第一个订阅者建立连接
8          }
9          return () => this.unsubscribe(callback);
10     }
11
12     private broadcast(data) {
13         this.subscribers.forEach(callback => callback(data));
14     }
15 }
```

12. 如何用Service Worker拦截AI流式请求，实现离线缓存、请求重试与带宽节省？

场景："印客学院"的PWA应用中，希望即使网络不稳定也能提供AI流式回答的部分功能，并能缓存常见问题的回答。

核心答案：使用Service Worker作为网络代理，拦截对AI流式接口的请求。离线时返回缓存的响应；在线时添加重试逻辑，对响应进行压缩/解压以节省带宽。

Service Worker策略：

1. 预缓存：安装时缓存常见问题的回答模板
2. 缓存优先：检查缓存，有则返回，无则请求
3. 网络优先：先尝试网络请求，失败则回退到缓存
4. 重试机制：网络请求失败时自动重试
5. 压缩传输：对响应进行gzip压缩（需服务器支持）

缓存策略：

- 静态回答：预缓存到Cache Storage
- 动态回答：运行时缓存，设置合适过期时间
- 存储管理：LRU策略清理旧缓存

- 版本管理：缓存版本号，避免旧缓存

13. 设计一个"流式数据可视化"方案，实时展示AI生成过程中的Token分布、注意力权重或置信度变化

场景："印客学院"的AI模型解释性工具中，希望将AI生成文本时的内部状态实时可视化，帮助理解AI的"思考过程"。

核心答案：从AI服务端获取额外的元数据（如每个Token的logits、注意力矩阵），前端使用Canvas或WebGL实时绘制热力图、概率分布图等。采用增量更新和采样策略处理大数据量。

可视化类型：

1. Token概率热力图：x轴为生成步骤，y轴为top_k Token，颜色表示概率
2. 注意力权重矩阵：显示当前Token与之前Token的关联强度
3. 置信度曲线：显示生成置信度随时间变化
4. Token分布饼图：显示当前步骤的概率分布

性能优化：

- 增量渲染：只更新新增数据部分
- 采样显示：数据点过多时进行采样
- 双缓冲Canvas：减少渲染闪烁
- WebGL加速：大数据量时使用WebGL渲染

14. 当AI流式输出包含结构化数据时，如何在前端逐步解析并验证其完整性？

场景："印客学院"的AI数据助手场景中，AI可能流式输出JSON或XML格式的结构化数据（如表格数据、配置对象）。

核心答案：使用状态机解析器逐步构建结构化数据。对于JSON，逐字符分析，跟踪大括号、中括号的配对情况，当检测到完整对象时进行解析和验证。对于XML，等待接收完整标签后再解析，或使用SAX风格解析器。

JSON流式解析：

1. 状态跟踪：括号深度、是否在字符串中、转义状态
2. 缓冲区管理：累积字符直到形成完整JSON
3. 完整性检测：括号深度为0时尝试解析
4. 错误恢复：解析失败时等待更多数据

XML流式解析：

1. 标签跟踪：记录打开标签栈
2. 部分解析：对不完整XML进行容错处理
3. 完整性验证：检查标签是否闭合
4. 错误处理：标签不匹配时的恢复策略

15. 如何用EventSource的last-event-id机制实现AI生成中断后的续接，确保数据不丢失？

场景："印客学院"的在线编辑器中，AI正在生成长篇文章，突然网络中断。重连后，希望从断点继续生成。

核心答案：利用SSE的 `last-event-id` 机制，客户端在重连时将上次收到的最后一个事件ID通过 `Last-Event-ID` 头发送给服务器，服务器从该ID之后继续发送事件。

实现步骤：

1. 服务器为每个事件分配唯一递增ID
2. 客户端监听事件，存储最后一个事件ID到本地存储
3. 连接中断后，重新创建EventSource，设置 `lastEventId`
4. 服务器收到 `Last-Event-ID` 头，从该ID之后的事件开始发送

客户端实现：

代码块

```
1  class ResumeableEventSource {
2    constructor(url) {
3      this.lastEventId = localStorage.getItem('lastEventId') || '';
4      this.eventSource = new EventSource(url, {
5        lastEventId: this.lastEventId
6      });
7
8      this.eventSource.onmessage = (event) => {
9        if (event.lastEventId) {
10          this.lastEventId = event.lastEventId;
11          localStorage.setItem('lastEventId', event.lastEventId);
12        }
13      };
14    }
15  }
```

16. 在低代码平台中，如何设计一个"流式UI生成器"，根据AI返回的JSON描述实时渲染表单、图表等组件？

场景："印客学院"的低代码平台中，用户用自然语言描述界面，AI流式返回UI的JSON描述（组件树、属性）。

核心答案：定义UI描述语言（JSON Schema），描述组件类型、属性、子组件等。前端维护组件映射表，将组件类型映射到React/Vue组件。当接收到流式JSON时，逐步构建组件树，使用虚拟DOM差异更新实现渐进式渲染。

UI描述协议：

代码块

```
1  {
2    "type": "Container",
3    "props": { "className": "app" },
4    "children": [
5      { "type": "Input", "props": { "placeholder": "请输入" } },
6      { "type": "Button", "props": { "label": "提交" } }
7    ]
8  }
```

渲染引擎：

- 1. 组件注册表：组件类型到实际组件的映射
- 2. JSON解析：流式解析UI描述JSON
- 3. 组件实例化：根据描述创建组件实例
- 4. 差异更新：比较新旧组件树，最小化更新
- 5. 渐进渲染：逐步显示生成的UI

17. 请实现一个"流式差异对比"功能，实时高亮AI编辑前后文本的差异（如语法修正、风格改写）

场景："印客学院"的写作助手中，AI对用户输入的文本进行流式改进（语法修正、风格优化）。希望实时显示修改前后的差异。

核心答案：使用差异算法（如Myers diff算法）比较原始文本和AI流式输出的文本，生成差异列表（插入、删除、替换）。然后在前端将差异实时高亮显示，用颜色区分新增、删除和修改内容。

差异算法流程：

- 1. 输入：原始文本、当前AI输出文本

2. 计算差异：生成操作序列（相等、插入、删除）
3. 转换为HTML： `<ins>` 标签表示新增， `<del>` 标签表示删除
4. 实时更新：每次AI输出新内容重新计算差异
5. 性能优化：增量计算差异，避免全量比较

显示效果：

- 新增内容：绿色背景
 - 删除内容：红色背景+删除线
 - 修改内容：删除旧内容+新增新内容
 - 实时更新：随着AI输出逐渐显示更多差异
-

18. 如何用WebRTC DataChannel替代SSE/WebSocket，实现P2P架构下的AI流式数据传输？

场景："印客学院"的分布式AI系统中，希望实现端到端的AI流式传输，减少服务器压力，支持点对点的实时AI协作。

核心答案：WebRTC DataChannel提供了浏览器之间的直接数据传输通道。建立过程需要信令服务器协助交换连接信息（SDP），之后数据直接在客户端之间传输。

建立流程：

1. 信令交换：通过WebSocket交换SDP和ICE候选
2. 建立连接：创建RTCPeerConnection
3. 创建通道：建立DataChannel
4. 数据传输：通过DataChannel发送/接收流式数据
5. 连接维护：处理断开、重连

优缺点：

- 优点：低延迟、P2P传输、减少服务器负载
- 缺点：需要信令服务器、NAT穿透可能失败、连接建立复杂

适用场景：

- 客户端之间的AI协作
 - 局域网内的AI服务发现
 - 边缘计算场景下的AI推理
-

19. 设计一个"流式内容审核"管道，在AI生成过程中实时调用敏感词过滤、图片鉴黄等异步服务

场景："印客学院"的社区AI生成内容中，需要在生成过程中实时审核，一旦发现违规内容立即停止生成。

核心答案：构建可插拔的审核管道，每个审核器（如敏感词、图片、违禁品）独立工作，并行或串行审核流式数据。审核结果通过事件通知，可中断流式生成。

管道设计：

代码块

```
1  interface Moderator {
2      name: string;
3      moderate(content: string): Promise<{ passed: boolean; reason?: string }>;
4  }
5
6  class ModerationPipeline {
7      private moderators: Moderator[] = [];
8
9      async process(content: string) {
10         const results = await Promise.all(
11             this.moderators.map(m => m.moderate(content))
12         );
13         return results.every(r => r.passed);
14     }
15 }
```

审核器类型：

1. 文本审核：敏感词、违禁词、政治敏感
2. 图片审核：鉴黄、鉴暴、OCR文字审核
3. 音频审核：语音转文字后审核
4. 视频审核：抽帧后图片审核+音频审核

处理策略：

- 并行审核：多个审核器同时工作
- 快速失败：任一审核器失败立即停止
- 分级审核：先快速检查，后深度分析
- 异步回调：审核结果通过事件或回调通知

20. 如何在前端实现"流式翻译记忆库"，将AI翻译的句子片段实时存储并用于后续相似句子的加速？


场景："印客学院"的多语言学习平台中，AI实时翻译用户输入的句子。希望将翻译结果存储为记忆库，当用户输入相似句子时，优先从记忆库中检索。

核心答案：使用向量相似度搜索（如sentence-transformers生成句子向量）或基于前缀树的模糊匹配。将翻译对（原文、译文）存储到IndexedDB，建立向量索引。新句子到来时，先搜索记忆库，找到高相似度的直接返回译文，否则调用AI翻译。

技术栈：

- 1. 向量化：将句子转换为向量（TensorFlow.js + Universal Sentence Encoder）
- 2. 存储：IndexedDB存储向量和翻译对
- 3. 检索：近似最近邻搜索（ANN）
- 4. 相似度计算：余弦相似度、欧氏距离
- 5. 缓存策略：LRU缓存常用翻译

工作流程：




21. 当AI流式输出被用户中途修改时，如何设计撤销/重做栈以保留每一步的流式状态？

场景："印客学院"的AI写作工具中，用户可能在中途修改AI生成的内容，需要支持撤销/重做功能，回退到任意历史状态。

核心答案：设计命令模式实现撤销/重做栈。每个用户操作（输入、删除、格式化）和AI生成的每个有意义片段都作为命令对象保存。栈中保存完整状态或差异，支持选择性保存流式状态。

命令设计：



```
4     redo(): void;
5 }
6
7 class TextInsertCommand implements Command {
8     constructor(private editor: Editor, private text: string, private pos:
        number) {}
9
10    execute() { this.editor.insert(this.text, this.pos); }
11    undo() { this.editor.delete(this.pos, this.text.length); }
12    redo() { this.execute(); }
13 }
```

流式状态保存策略：

1. 完整快照：每个操作保存完整文档状态（内存消耗大）
2. 差异保存：只保存变化部分（需计算差异）
3. 检查点：定期保存完整状态，之间保存差异
4. 选择性保存：只保存用户操作，AI生成作为原子操作

栈管理：

- 最大深度限制防止内存溢出
- 分支支持（实验性功能）
- 状态序列化/反序列化
- 与AI流式生成的集成

22. 请设计一个"流式数据分片上传"方案，将用户输入的大文件（如视频）切片后流式发送给AI处理

场景："印客学院"的视频分析功能中，用户上传大视频文件给AI分析，需要支持断点续传、进度显示和并行上传。

核心答案：将大文件分割为固定大小的块（如5MB），使用可恢复上传协议（如Tus协议）或自定义分片上传。前端管理分片上传队列，支持暂停、恢复、重试和并行上传。

上传流程：

1. 文件分片：按固定大小切割文件
2. 创建上传任务：生成唯一上传ID
3. 上传分片：并行上传多个分片
4. 服务端合并：所有分片上传完成后合并

5. 通知AI处理：调用AI处理接口

关键特性：

- 断点续传：记录已上传分片，中断后可继续
- 并行上传：多个分片同时上传
- 进度计算：基于已上传分片计算进度
- 错误重试：失败分片自动重试
- 暂停/恢复：手动暂停和恢复上传

代码结构：

代码块

```
1  class ChunkedUploader {
2    async upload(file: File, onProgress: (progress: number) => void) {
3      const chunkSize = 5 * 1024 * 1024; // 5MB
4      const totalChunks = Math.ceil(file.size / chunkSize);
5      const uploadId = await this.createUploadSession(file);
6
7      for (let i = 0; i < totalChunks; i++) {
8        const chunk = file.slice(i * chunkSize, (i + 1) * chunkSize);
9        await this.uploadChunk(uploadId, chunk, i);
10       onProgress((i + 1) / totalChunks * 100);
11     }
12
13     await this.completeUpload(uploadId);
14   }
15 }
```

23. 如何用TransformStream在浏览器侧对AI流式输出进行实时转码（如Base64解码、gzip解压）？

场景："印客学院"的AI服务返回gzip压缩的流式数据，需要在浏览器端实时解压；或返回Base64编码的二进制数据，需要实时解码。

核心答案：使用Streams API的TransformStream创建转换流，在fetch的Response.body上添加转换管道，实时处理流式数据。可用于解码、解压、格式转换等操作。

TransformStream示例：

代码块

```
1  // Base64解码TransformStream
```

```
2  class Base64Decoder extends TransformStream {
3      constructor() {
4          super({
5              transform(chunk, controller) {
6                  const text = new TextDecoder().decode(chunk);
7                  const decoded = atob(text); // Base64解码
8                  controller.enqueue(new TextEncoder().encode(decoded));
9              }
10         });
11     }
12 }
13
14 // 使用
15 fetch('/ai-stream')
16   .then(response => {
17       const decodedStream = response.body
18         .pipeThrough(new Base64Decoder())
19         .pipeThrough(new TextDecoderStream());
20
21       return new Response(decodedStream);
22   });
```

常见转换：

1. Base64解码/编码
2. gzip解压/压缩（使用CompressionStreams API）
3. 字符编码转换（UTF-8 ↔ UTF-16）
4. JSON流解析
5. 数据格式转换（CSV → JSON）

性能考虑：

- 流式处理避免内存峰值
- 适当缓冲区大小平衡延迟和吞吐
- Worker中处理CPU密集型转换
- 错误处理和恢复机制

24. 在AI代码生成场景中，如何实现流式输出的"实时语法检查"与错误高亮？


场景："印客学院"的AI代码助手中，AI流式生成代码时，需要实时检查语法错误并高亮显示，帮助用户及时发现错误。

核心答案：集成代码语法检查器（如ESLint、TypeScript编译器、pyflakes等）到前端，在流式输出过程中定期检查代码语法。使用Web Worker避免阻塞主线程，实时高亮错误位置。

实现方案：

- 1. 语法检查器选择：根据语言选择合适检查器
- 2. 增量检查：每次新增代码时只检查受影响部分
- 3. 延迟检查：防抖处理避免频繁检查
- 4. 错误高亮：在代码编辑器中标记错误位置
- 5. 错误解释：提供错误原因和修复建议

工作流程：



Web Worker集成：

代码块

```
1 // 主线程
2 const worker = new Worker('code-checker.js');
3 worker.onmessage = (event) => {
4   const errors = event.data;
5   // 更新错误高亮
6 };
7
8 function checkCode(code) {
9   worker.postMessage({ code, language: 'javascript' });
10 }
11
12 // Worker线程
13 importScripts('eslint.js', 'babel-parser.js');
14 self.onmessage = (event) => {
15   const { code, language } = event.data;
16   const errors = eslint.verify(code, { parser: 'babel' });
17   self.postMessage(errors);
18 };
```

25. 设计一个"多模型流式对比"界面，同时展示GPT、Claude等不同模型的生成过程，并支持并行暂停/继续

场景："印客学院"的模型对比工具中，用户输入一个问题，同时发送给多个AI模型（GPT-4、Claude、Gemini），实时对比它们的生成过程和结果。

核心答案：创建多个并行的流式连接，每个连接对应一个AI模型。使用统一的控制器管理所有连接的启动、暂停、继续和停止。设计对比界面并排显示各模型的生成过程，支持同步滚动和进度对比。

架构设计：

1. 模型管理器：管理多个模型连接实例
2. 统一控制器：控制所有模型的播放状态
3. 数据同步：确保各模型时间轴对齐
4. 视图对比：并排或分栏显示对比结果

控制器功能：

代码块

```
1  class MultiModelController {
2      private models: Map<string, ModelStream> = new Map();
3      private state: 'playing' | 'paused' = 'playing';
4
5      async startAll(prompt: string) {
6          for (const [name, model] of this.models) {
7              model.start(prompt);
8          }
9      }
10
11     pauseAll() {
12         this.state = 'paused';
13         for (const model of this.models.values()) {
14             model.pause();
15         }
16     }
17
18     resumeAll() {
19         this.state = 'playing';
20         for (const model of this.models.values()) {
21             model.resume();
22         }
23     }
24 }
```

对比界面设计：

1. 并排视图：多个编辑器水平排列
2. 同步滚动：一个编辑器滚动时其他跟随
3. 进度对比：显示各模型的生成速度和进度
4. 差异高亮：高亮不同模型的输出差异
5. 模型标签：清晰标识每个模型的输出

性能优化：

- 虚拟滚动：大量输出时使用虚拟滚动
- 增量渲染：只渲染可视区域内容
- 节流更新：控制UI更新频率
- 内存管理：清理历史数据防止内存泄漏